MANUALE D'USO

devon

Il gestore documentale personale in puro Python: indicizzazione full-testo delle proprie cartelle, ricerca con frammenti evidenziati, tag, gruppi smart, «vedi anche» e duplicati, esportazione su disco esterno. Senza dipendenze e senza mai toccare i file originali.

Versione 0.1 · Ottobre 2026 · multipiattaforma

Sommario

1. Che cos'è devon **3**

2. Installazione **3**

2.1 macOS . . . 3

2.2 Componenti opzionali . . . 4

3. Indicizzare le cartelle **4**

4. L'interfaccia grafica web **5**

4.1 Barra laterale . . . 5

4.2 Ricerca e lista documenti . . . 5

4.3 Scheda documento . . . 5

4.4 Cartelle e indice . . . 5

5. La riga di comando **6**

6. Sintassi di ricerca **7**

7. Formati di file supportati **7**

7.1 Testo completo, senza installare nulla . . . 7

7.2 Testo completo con componenti opzionali . . . 8

7.3 Solo metadati (ricercabili per nome) . . . 8

8. Organizzare l'archivio **8**

8.1 Tag e gruppi . . . 8

8.2 Gruppi smart . . . 9

8.3 Vedi anche . . . 9

8.4 Duplicati . . . 9

9. Esportare e fare backup **9**

10. Limiti noti **10**

11. Ricerca semantica e classificazione **10**

12. Domande frequenti **11**

Posso cancellare i documenti con devon? . . . 11

Ho spostato dei file: l'indice è da rifare? . . . 11

Il database è portabile? . . . 11

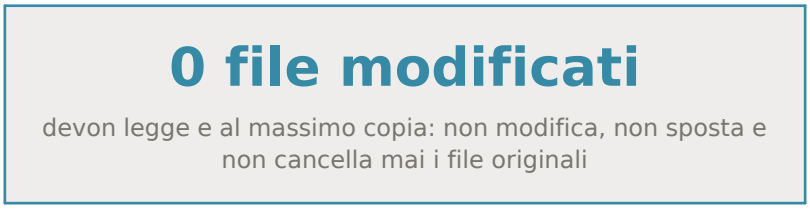
Quanto è grande l'indice? . . . 11

Come cerco una frase esatta? 11

1. Che cos'è devon

devon è un gestore documentale personale che replica le funzioni essenziali di DEVONthink usando solo Python e la sua libreria standard: indicizza le cartelle del computer in un database SQLite, offre ricerca full-testo con frammenti evidenziati, tag, gruppi (anche «smart», a query), suggerimenti «vedi anche» basati sulla similarità dei testi, rilevamento dei duplicati ed esportazione verso un disco esterno.

È pensato per organizzare e ritrovare i propri documenti prima di riconsegnare un computer aziendale, ma vale come archivio personale generale. Il caso tipico: si indicizzano le cartelle Documenti, Scrivania e Download del Mac, si ritrovano i file cercando parole chiave, si organizzano con tag e gruppi (per esempio «personale» e «consiglio di amministrazione») e infine si esporta la selezione su una chiavetta o un disco esterno.



Tutto l'archivio vive in un unico file di database, preimpostato in `~/.devon/library.db`. Per usare un percorso diverso si usa l'opzione `--db` o la variabile d'ambiente `DEVON_DB`. Il backup dell'intero archivio è la copia di quel singolo file; l'indice è sempre ricostruibile rilanciando l'importazione sulle stesse cartelle.

I requisiti sono minimi: Python 3.6 o successivo, senza alcuna libreria da installare. Sul Mac 2013 funziona quindi senza preparativi; due componenti opzionali (testo dei PDF e OCR) si aggiungono solo se servono, come descritto nel capitolo 2.

2. Installazione

2.1 macOS

1. Copiare la cartella del progetto (quella contenente il pacchetto `devon/`) sul Mac, per esempio in `~/devon-app`.

```
cd ~/devon-app
python3 -m devon init # crea ~/.devon/library.db
```

Se `python3` risultasse assente, installare gli strumenti da riga di comando di Apple:

```
xcode-select --install
```

Verifica rapida del componente di ricerca full-testo (è incluso in tutte le versioni recenti di Python):

```
python3 -c "import sqlite3; sqlite3.connect(':memory:').execute("CREATE VIRTUAL TABLE t
USING fts5(x)"); print('FTS5 ok')"
```

2.2 Componenti opzionali

- **Testo dei PDF** — `pip3 install --user pypdf`: estrae il testo dai PDF digitali (autore e titolo inclusi, quando presenti).
- **OCR** — `pip3 install --user pytesseract` più Tesseract (`brew install tesseract tesseract-lang`, con lingua italiana): riconosce il testo di immagini e PDF scannerizzati.

Senza questi componenti i PDF e le immagini vengono comunque indicizzati con i metadati e restano ricercabili per nome file; si perde solo la ricerca dentro il contenuto. Windows e Linux sono supportati allo stesso modo: servono solo Python 3 e, per l'OCR, l'eseguibile Tesseract per la propria piattaforma.

3. Indicizzare le cartelle

L'importazione legge ricorsivamente una cartella, calcola l'impronta SHA-256 di ogni file (base del rilevamento duplicati), estrae il testo secondo il formato e aggiorna l'indice. Rilanciando lo stesso comando, i file non modificati dall'ultima volta vengono saltati e quelli cambiati aggiornati.

```
python3 -m devon import ~/Documents ~/Desktop ~/Downloads
```

Il riepilogo a fine importazione riporta:

Voce	Significato
`visti`	file esaminati durante la scansione
`nuovi`	file aggiunti all'indice
`aggiornati`	file già in indice ma modificati dopo l'ultima importazione
`doppioni`	file con contenuto identico (stesso SHA-256) ad altro già presente
`saltati`	file vuoti o oltre 250 MB (video, immagini disco...)
`errori`	file non leggibili, comunque indicizzati con i soli metadati

Per impostazione predefinita vengono ignorati file e cartelle nascosti (quelli che iniziano con un punto) e le cartelle di rumore tipiche di una home: Library, .Trash, .cache, .git, node_modules, __pycache__, .venv, .npm, .docker. Le opzioni `--hidden` e `--exclude NOME` (ripetibile) modificano questo comportamento. L'importazione è

disponibile anche dall'interfaccia web, con avanzamento in tempo reale.

4. L'interfaccia grafica web

```
python3 -m devon serve # apre il browser su http://127.0.0.1:8300
```

Opzioni: `--port` (porta, predefinita 8300), `--host` e `--no-browser` per non aprire il browser. L'interfaccia è divisa in tre pannelli, nello stile di DEVONthink.

4.1 Barra laterale

Mostra il totale dei documenti, l'accesso alla vista Duplicati, il filtro per tipo con conteggi, l'elenco dei gruppi (quelli smart sono contrassegnati) e la nuvola dei tag. Un clic su tipo, gruppo o tag applica subito quel filtro alla lista.

4.2 Ricerca e lista documenti

La casella di ricerca filtra in tempo reale mentre si digita, con la sintassi del capitolo 6; i risultati mostrano titolo, tipo, data, frammento del testo con le parole cercate evidenziate e tag. Un clic su un documento ne apre la scheda.

4.3 Scheda documento

- **Apri file** — mostra il file originale nel browser (PDF, immagini, testo...) o lo scarica con «Scarica»;
- **Tag** — aggiunti digitando il nome, rimossi con la × sulla chip;
- **Gruppi** — assegnazione da elenco o creazione di un gruppo nuovo al volo;
- **Vedi anche** — fino a otto documenti affini, con punteggio di similarità;
- **Rimuovi dall'indice** — toglie il documento dall'archivio senza toccare il file su disco.

4.4 Cartelle e indice

Il pulsante «Cartelle e indice» apre la gestione delle sorgenti: l'elenco permanente dei percorsi da indicizzare, ciascuno con il numero di documenti indicizzati e la data dell'ultima scansione. Si aggiungono percorsi (verificati all'inserimento), si rimuovono dalla lista (i documenti già indicizzati restano) e si aggiorna una singola cartella o tutte con «Aggiorna tutto l'indice».

L'aggiornamento è incrementale: rileva i file **nuovi e modificati** (confrontando data e ora di modifica) e re-indicizza solo quelli, saltando in pochi istanti tutto il resto. Lo stato della scansione — cartella in corso, file visti, nuovi, aggiornati e duplicati — è visibile in tempo reale nello stesso pannello, e a fine lavoro lista e barra laterale si ricaricano da

sole.

5. La riga di comando

Comando	Che cosa fa
`init`	crea/apre il database
`import PERCORSO...`	indicizza cartelle o file (incrementale)
`ls [--kind --tag --group]`	elenca i documenti con filtri; --json per output JSON
`search QUERY`	ricerca full-testo con frammenti evidenziati
`show ID`	dettagli: metadati, testo, tag, gruppi, vedi anche
`rm ID...`	rimuove dall'indice (i file restano al loro posto)
`tag ID +t -t`	aggiunge o rimuove tag a un documento
`tags`	elenca i tag in uso con i conteggi
`group add NOME [--parent P] [--query Q]`	crea gruppo, sottogruppo o gruppo smart
`group ls / rm NOME`	elenca o elimina i gruppi
`group put NOME ID...`	mette documenti in un gruppo
`similar ID`	documenti affini (similarità del coseno su TF-IDF)
`dupes`	gruppi di duplicati a confronto di contenuto
`stats`	statistiche dell'archivio
`check`	elenca i file indicizzati non più presenti su disco
`export --dest CARTELLA`	copia documenti (per query, tag, gruppo o ID)
`serve`	avvia l'interfaccia web

Esempi d'uso corrente:

```
python3 -m devon search "consiglio amministrazione"
python3 -m devon tag 42 +personale +consiglio-alfa
python3 -m devon group add "Consiglio Alfa" --query "alfa verbale consigl*"
python3 -m devon export --tag personale --dest /Volumes/Backup/personale
```

6. Sintassi di ricerca

Le parole cercate vengono combinate tra loro (tutte presenti); filtri e testo libero si mescolano nella stessa query. Gli accenti non sono un problema: «perché» trova anche «perche» e viceversa, e il nome del file fa parte del testo indicizzato.

Query di esempio	Effetto
`verbale assemblea`	documenti che contengono entrambe le parole
`consigl*`	prefisso: consiglio, consigliere, consiglio delegato...
`bilancio -bozza`	con «bilancio» ma senza «bozza»
`tag:personale`	solo i documenti con quel tag
`kind:pdf`	filtro per tipo (pdf, email, testo, «pagina web»...)
`ext:.docx`	filtro per estensione del file
`path:consigli`	filtro sul percorso del file
`group:personale`	dentro un gruppo, sottogruppi inclusi
`assemblea tag:personale kind:pdf`	parola + due filtri insieme

7. Formati di file supportati

Ogni file, di qualunque formato, viene indicizzato con nome, percorso, data, dimensione e impronta SHA-256, quindi è sempre ricercabile per nome. La differenza tra i formati sta nell'estrazione del contenuto: tre livelli.

7.1 Testo completo, senza installare nulla

Formati	Tipo	Note
`.txt .md .csv .tsv .log`	testo	lettura diretta
`.json .xml .yaml .yml .ini`	testo	lettura diretta
`.py .sh .js .css .applescript`	testo	codice sorgente
`.html .htm`	pagina web	script e fogli di stile ignorati
`.rtf`	testo	estrae i gruppi di testo
`.docx`	Word	testo e autore dai metadati
`.xlsx`	Excel	stringhe condivise e valori delle celle

Formati	Tipo	Note
`.pptx`	PowerPoint	testo delle slide, in ordine
`.odt .ods .odp`	Word/Excel/PowerPoint	testo e autore
`.doc .xls .ppt`	Office storico	estrazione euristica del testo dai file binari (cp1252 e UTF-16): ricerca completa, impaginazione non ricostruita
`.epub`	e-book	tutti i capitoli
`.eml .emlx`	email	intestazioni (Da, A, Oggetto, Data) e corpo

7.2 Testo completo con componenti opzionali

Formati	Tipo	Note
`.pdf`	PDF	con pypdf: testo, autore e titolo; se il PDF è una scansione senza testo si passa all'OCR
`.png .jpg .jpeg`	immagine	con pytesseract + Tesseract: OCR nelle lingue italiana e inglese
`.tif .tiff .gif .bmp .heic`	immagine	come sopra, nei formati supportati da Tesseract

7.3 Solo metadati (ricercabili per nome)

Formati	Tipo	Note
`.webarchive`	pagina web	archivio Safari: nessuna estrazione
`.zip .dmg .rar`	archivio	indicizzati con i soli metadati
`audio e video`	audio / video	saltati se oltre 250 MB
`qualsiasi altro formato`	altro	indicizzato con nome, percorso, data e hash

Il titolo mostrato nell'archivio deriva dai metadati del PDF (quando presenti) oppure dalla prima riga significativa del testo; in mancanza, dal nome del file. I testi oltre 400.000 caratteri vengono troncati per non gonfiare il database.

8. Organizzare l'archivio

8.1 Tag e gruppi

I tag sono etichette libere applicabili sia dall'interfaccia web sia da riga di comando; un documento può averne quanti si vuole. I gruppi sono contenitori con un nome,

eventualmente annidati (`--parent`): una stessa raccolta «Consiglio Alfa» può contenere il sottogruppo «Verbali».

8.2 Gruppi smart

Un gruppo smart non ha membri fissi: la sua query ne calcola il contenuto a ogni apertura. È la versione devon delle ricerche salvate di DEVONthink, e accetta tutta la sintassi del capitolo 6.

```
python3 -m devon group add "Documenti Alfa" --query "alfa consigl* tag:alfa"
python3 -m devon group add "Personale" --query "tag:personale -cantiere"
```

8.3 Vedi anche

Il comando `similar` (e il riquadro nella scheda documento) confronta il testo di ogni documento con gli altri usando la similarità del coseno su vettori TF-IDF, dopo aver scartato le parole più comuni in italiano e inglese. Il risultato è un punteggio tra 0 e 1: le copie identiche totalizzano 1.00, i documenti dello stesso argomento valgono tipicamente 0.2-0.4.

8.4 Duplicati

La vista Duplicati (web) e il comando `dupes` raggruppano i file con lo stesso contenuto, mostrando tutti i percorsi. Per ripulire l'archivio si toglie dall'indice la copia in eccesso con «Rimuovi dall'indice» o `rm ID`: il file su disco non viene tocccato.

9. Esportare e fare backup

L'esportazione copia i documenti selezionati in una cartella di destinazione, tipicamente un disco esterno; i file con lo stesso nome vengono rinominati automaticamente (nome__2.ext).

```
python3 -m devon export --tag personale --dest /Volumes/Backup/personale
python3 -m devon export --group "Consiglio Alfa" --dest /Volumes/Backup/alfa
python3 -m devon export --query "bilancio" --dest ~/Selezione
python3 -m devon export 12 15 33 --dest ~/Selezione
```

I file non più presenti su disco vengono segnalati ma non bloccano l'esportazione; il comando `check` elenca in anticipo gli indirizzi orfani. Il backup dell'archivio è la copia del file `~/.devon/library.db` (eventualmente insieme ai file `-wal` e `-shm` se l'applicazione è in uso): quell'unico file contiene testi, tag, gruppi e configurazione.

10. Limiti noti

• PDF senza pypdf installato: nessun testo estraibile, il documento resta ricercabile solo per nome file e metadati;

• formati Office storici (.doc, .xls, .ppt) e fogli di calcolo: nessuna estrazione del contenuto;

• l'OCR è lento su macchine datate e la qualità dipende dalla risoluzione delle scansioni;

• l'interfaccia web non cancella e non sposta file: è una scelta deliberata; ogni operazione distruttiva resta su riga di comando;

• la similarità «vedi anche» lavora sulle parole, non sul significato: documenti con lessico diverso ma stesso argomento possono non risultare affini.

11. Ricerca semantica e classificazione

Oltre alla ricerca per parola, devon sa cercare e organizzare i documenti **per significato**, con tutto il calcolo eseguito in locale. Nella barra di ricerca della web gui basta attivare la casella «semantica»: la query viene confrontata con il significato di ogni documento, così «rendiconto finanziario» trova anche un «bilancio d'esercizio» scritto con parole diverse. I filtri (kind:, tag:, path:...) restano attivi anche in modalità semantica.

Funzione	Dove	Che cosa fa
Ricerca semantica	casella «semantica» / semsearch	ordina i documenti per affinità di significato con la query
Embedding a blocchi	«Calcola embedding» / embed	i tipi documento vengono spezzati in passaggi da ~1000 caratteri e tutto il contenuto viene vettorizzato: un documento è affine se lo è una sua parte
Categorie semantiche	gruppo smart sem:...	membri = corrispondenze lessicali esatte + affini per significato sopra soglia; es. gruppo «Honda» con query sem:honda moto
Argomenti	«Raggruppa» / cluster	k-means per contenuti: assegna un argomento con etichetta automatica (es. «07 · verbale · consiglio»), filtrabile con topic:
Documenti simili	scheda documento / similar	gli affini per significato, calcolati sul miglior blocco; classify suggerisce o assegna i gruppi per contenuto

Il modello (paraphrase-multilingual-MiniLM-L12-v2, eseguito in locale via fastembed) è ottimizzato per testi brevi: per questo i documenti lunghi vengono vettorizzati a blocchi.

I file indicizzati col solo nome non entrano nel rango semantico — restano trovabili per nome. Senza fastembed le stesse funzioni restano attive con un rango a similarità vettoriale TF-IDF.

12. Domande frequenti

Posso cancellare i documenti con devon?

No, e non per caso: la rimozione (`rm` o il pulsante nell'interfaccia) toglie il documento dall'indice, nulla più. I file originali si gestiscono con il Finder. In contesti delicati (per esempio prima di riconsegnare un computer aziendale) questa separazione evita passi falsi.

Ho spostato dei file: l'indice è da rifare?

No. Basta rilanciare l'importazione sulle nuove posizioni: i file spostati vengono ri-indicizzati e, grazie all'hash, riconosciuti come lo stesso contenuto. Con `check` si vedono i vecchi percorsi rimasti orfani, da pulire con rm.

Il database è portabile?

Sì: è un file SQLite standard, leggibile su macOS, Windows e Linux. Copiandolo su un altro computer l'archivio funziona; i collegamenti ai file originali restano validi finché i percorsi non cambiano.

Quanto è grande l'indice?

Dipende dal numero e dalla natura dei documenti: in genere qualche centinaio di kilobyte per centinaio di documenti testuali; i testi troncati a 400.000 caratteri tengono sotto controllo i volumi.

Come cerco una frase esatta?

Le parole della query si combinano in AND: per una frase si usano più parole specifiche o un prefisso. La ricerca a prefisso (`consigl*`) è lo strumento più efficace quando la forma esatta della parola è incerta.